

罗文杰

AI推理与模型评测工程师 | 2027 届

+86 183 1949 6086 | e1576499@u.nus.edu
github.com/LUOaini1213 | luoaini1213.github.io

核心优势

以同硬件对照、精度门和逐场景统计检验定位性能与模型行为。具备SGLang/vLLM部署压测、GPU算子实验和PyTorch训练经验，将日志、源码与干预实验连接为可复算证据。

教育背景

新加坡国立大学 | 硕士 • 交通运输工程 2025.08 - 2027.01

研究方向：交通信息工程及控制

长安大学 | 本科 • 交通运输 2021.09 - 2025.06

GPA 3.16/5.0; 专业约前 15%

实习经历

新加坡远东幕墙 | 工程部 • 项目工程师 2026.06 - 至今

- 用Python解析发运与测试邮件，结构化提取批次及检测结果，支持15种材料的状态跟踪与工程协同。

彩讯科技 | 产品实习生 2025.06 - 2025.08

- 撰写3份PRD并定义验收标准，完成5页Axure原型进入开发；通过功能验证和缺陷反馈衔接产品与研发。

项目经历

SGLang/vLLM推理服务与性能归因 2026.09

- 在T4与Qwen2.5-0.5B上做受控实验，定位SGLang解码图默认捕获至batch 8导致的吞吐台阶，以关闭图和扩展捕获上限验证机制。
- 将decode max batch设为32，同轮batch 32吞吐608→2690 tok/s (4.42倍)；关图代价按原先是否捕获分组，日志、参数及每档单次测量留档。

fp16x3 Transformer GPU优化 2026.08.23-至今

- 自写Triton融合核拆分fp16高低位，构造一次K三倍的cuBLAS张量核GEMM；结合融合注意力与批分块降低显存需求。
- T4上13/13形状通过精度门，最差绝对误差9.5e-6；逐形状三次独立跑的中位加速2.83倍，100k序列在14.2GB内完成。

NAVSIM | 规划模型训练与评测 2026.08-2026.09

- 在103,288场navtrain训练MLP、12,146场navtest评测；地图×他车输入做2×2因子设计，每格三种子，同一cache计算配对95%置信区间。
- 先复现恒速20.7/论文20.6与Human94.6/论文94.8；已有地图后加入真值框，三种子PDMS均显著下降而开环L1几乎不变，支持用任务指标选型。

技能

推理与性能：SGLang、vLLM、CUDA C++、Triton、PyTorch、CUDA Graph

评测：受控实验、精度校验、配对bootstrap、因子设计、多种子、防泄漏切分